

Краткое введение в Большие языковые модели

Евгений Борисов

Большие языковые модели

LLM - большая языковая модель, содержит большое количество параметров

GPT-3 (OpenAI, 2020) - 175 миллиардов параметров


LLaMA (Meta AI, 2023) - 7 до 65 миллиардов параметров (140 GB)

LMSYS Chatbot Arena Leaderboard

<https://huggingface.co/spaces/lmsys/chatbot-arena-leaderboard>

Rank ▲	Model ▲	★ Arena Elo ▲	95% CI ▲	Votes ▲	Organization
1	Claude 3 Opus	1253	+5/-5	33250	Anthropic
1	GPT-4-1106-preview	1251	+4/-4	54141	OpenAI
1	GPT-4-0125-preview	1248	+4/-4	34825	OpenAI
4	Bard (Gemini Pro)	1203	+5/-7	12476	Google
4	Claude 3 Sonnet	1198	+5/-5	32761	Anthropic
6	GPT-4-0314	1185	+5/-4	33499	OpenAI
6	Claude 3 Haiku	1179	+5/-5	18776	Anthropic
8	GPT-4-0613	1158	+4/-5	51860	OpenAI
8	Mistral-Large-2402	1157	+5/-4	26734	Mistral
9	Qwen1.5-72B-Chat	1148	+5/-5	20211	Alibaba
10	Claude-1	1146	+6/-6	21908	Anthropic
10	Mistral-Medium	1145	+5/-4	26196	Mistral

Нейросетевые языковые модели



Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

Radford A. et al. Improving language understanding by generative pre-training. - 2018

Схема обучения модели на основе GPT

- Предобучение на корпусе $\mathcal{U}$ (без учителя)

$$\begin{aligned}h_0 &= UW_e + W_p; \\h_i &= \text{transformer}(h_{i-1}), i = \overline{1, n} \\P(u) &= \text{softmax}(h_n W_e^T)\end{aligned}$$

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- Донастройка под целевую задачу на корпусе $\mathcal{C}$ (с учителем)

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m)$$


$$L(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C});$$

Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

Radford A. et al. Improving language understanding by generative pre-training. - 2018

Различные варианты применения GPT



Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

GPT: Radford A. et al. Improving language understanding by generative pre-training. - 2018
- 12 слоев трансформера



GPT-2: Radford A. et al. Language models are unsupervised multitask learners - 2019
- 48 слоев трансформера
- Больше корпус для обучения (40 GB текста)
- Другая токенизация: BPE по байтам, а не по символам
- передвинут Layer normalization
- изменена инициализация

GPT-3: Brown T. B. et al. Language models are few-shot learners - 2020.
(почти не отличается от GPT-2)
- 96 слоев трансформера
- Еще больше корпус для обучения (570 GB текста)
- Еще больше контекст (2048 токенов)

Большие языковые модели

Тюнинг базовой модели под свою задачу

- прямое дообучение
- частичное дообучение PEFT/LoRA
- RAG (Retrieval-Augmented Generation)



Большие языковые модели

для обучения LLM с нуля требуются большие ресурсы

датасет из текстов 3ТВ

кластер из 200 GPU

процесс может занимать несколько недель

Большие языковые модели

платные API и предобученные модели в открытом доступе

HuggingFace <https://huggingface.co>


The screenshot displays the Hugging Face website interface. At the top, there's a navigation bar with the Hugging Face logo, a search bar, and links to Models, Datasets, Spaces, Posts, Docs, Solutions, Pricing, and Log In. Below the navigation bar, the left sidebar shows a 'Tasks' section with filters for Multimodal, Computer Vision, and Natural Language Processing. The main content area is titled 'Models 70,402' and features a list of models. Each model entry includes the model name, its capabilities, and statistics like the number of downloads and likes. The models listed include:

- databricks/dbrx-instruct**: Text Generation, Updated about 16 hours ago, 9.36k downloads, 529 likes.
- ai21labs/Jamba-v0.1**: Text Generation, Updated about 11 hours ago, 293 downloads, 450 likes.
- xai-org/grok-1**: Text Generation, Updated about 18 hours ago, 31.3k downloads, 1.8k likes.
- databricks/dbrx-base**: Text Generation, Updated about 16 hours ago, 1.68k downloads, 294 likes.
- mistralai/Mistral-7B-Instruct-v0.2**: Text Generation, Updated 5 days ago, 2.09M downloads, 1.49k likes.
- Nexusflow/Starling-LM-7B-beta**: Text Generation, Updated 2 days ago, 5.7k downloads, 174 likes.
- google/gemma-7b**: Text Generation, Updated 30 days ago, 163k downloads, 2.65k likes.
- alpindale/Mistral-7B-v0.2-hf**: Text Generation, Updated 4 days ago, 8.35k downloads, 121 likes.
- meta-llama/Llama-2-7b-chat-hf**: Text Generation, Updated 10 days ago, 1.36M downloads, 3.22k likes.
- mistralai/Mixtral-8x7B-Instruct-v0.1**: Text Generation, Updated 29 days ago, 965k downloads, 3.5k likes.
- stabilityai/stable-code-instruct-3b**: Text Generation, Updated 1 day ago, 1.76k downloads, 82 likes.
- NousResearch/Hermes-2-Pro-Mistral-7B**: Text Generation, Updated about 14 hours ago, 38.7k downloads, 347 likes.
- Qwen/Qwen1.5-MoE-A2.7B**: Text Generation, Updated about 20 hours ago, 124 downloads, 60 likes.
- hpc-ai-tech/grok-1**: Text Generation, Updated 1 day ago, 1.15k downloads, 56 likes.
- CohereForAI/c4ai-command-r-v01**: Text Generation, Updated about 20 hours ago, 27.1k downloads, 750 likes.
- meta-llama/Llama-2-7b**: Text Generation, Updated 10 days ago, 3.74k downloads, 750 likes.
- mistralai/Mistral-7B-v0.1**: Text Generation, Updated Dec 11, 2023, 2.78M downloads, 3.03k likes.
- mLabonne/Beyonder-4x7B-v3**: Text Generation, Updated about 13 hours ago, 739 downloads, 41 likes.

Большие языковые модели

Прoxy для API сервисов LLM

<https://openrouter.ai/models>




Большие языковые модели

предобученные и модифицированные модели для русского языка

<https://huggingface.co/ai-forever>

<https://huggingface.co/IlyaGusev>



Models 79 Sort: Recently Updated

Model Name	Description	Updated	Downloads	Likes
ai-forever/kandinsky3-diffusers		Updated Feb 20	13	2
ai-forever/ruT5-base	Text2Text Generation	Updated Dec 11, 2023	5.92k	13
ai-forever/FRED-T5-large	Text2Text Generation	Updated Dec 5, 2023	2.46k	17
ai-forever/mGPT	Text Generation	Updated Dec 5, 2023	47k	218
ai-forever/rugpt2large		Updated Dec 5, 2023	411	7
ai-forever/ruT5-large	Text2Text Generation	Updated Dec 28, 2023	659	32
ai-forever/FRED-T5-1.7B	Text2Text Generation	Updated Dec 5, 2023	4.04k	63
ai-forever/mGPT-13B	Text Generation	Updated Dec 5, 2023	1.51k	46
ai-forever/ruGPT-3.5-13B	Text Generation	Updated Dec 5, 2023	3.82k	215
ai-forever/rugpt3small_based_on_gpt2	Text Generation	Updated Dec 5, 2023	11.8k	25

Большие языковые модели

квантование LLM

может уменьшать размер базовой модели на порядок
путём снижения точности (количества бит) вычислений (float32 в int8)
при некритичном понижении качества результата

снижаются требования к производительности аппаратуры

системы инференса квантованных моделей - Ollama, vLLM



Большие языковые модели

Prompting — правила конструирования запросов для LLM

- обозначение роли
- чёткая формулировка задачи
- определение формата ответа
- примеры вопросов и ответов

<https://habr.com/ru/articles/865952/>

Литература

Литература

Борисов Е.С. Методы машинного обучения. 2024
https://github.com/mechanoid5/ml_lectorium_2024_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2024
https://github.com/mechanoid5/ml_nlp_2024_I

Майоров В.Д. Основы обработки текстов. 10. Языковые модели. ИСП РАН, 2021
https://www.youtube.com/watch?v=_8MGdpt4I9M

Тихомиров М.М. Основы обработки текстов. 14. Большие языковые модели. ИСП РАН, 2023
https://www.youtube.com/watch?v=EC6_rMs1vsY

Нейчев Радослав Self-Attention. Transformer overview. Лекторий ФПМИ, 2020
<https://www.youtube.com/watch?v=UETKU1YE6g>

Jay Alammar Transformer в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/486358/>

Jay Alammar GPT-2 в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/490842/>