

Retrieval Augmented Generation (RAG)

Евгений Борисов


Retrieval Augmented Generation (RAG)

RAG - конструктор контекста для LLM

Индексация — формирование базы знаний из документов;

Извлечение — подбор релевантных запросу текстов;

Генерация — LLM генерирует ответ по запросу и найденному контексту;



Retrieval Augmented Generation (RAG)

Формирование базы знаний из документов

- Разделение документов (чанкинг)
- Векторизация чанков (эмбединги)
- Сохранение эмбедингов в векторную БД

Разделение документов на блоки данных (chunking)

- Извлечение текста из документов
- Обработка картинок

Возможные стратегий чанкинга:

- на равные части,
- на синтаксические блоки,
- на семантически завершенные блоки,

Применяем перекрытие блоков

Векторизация чанков (embeddings)



применяем специальные модели
преобразуем текст в семантические векторы

Векторное хранилище

- храним пары [вектор, текст]
- задаем метрику
- ищем векторы близкие к эмбедингу запроса
- реализации FAISS, QDRANT

Retrieval Augmented Generation (RAG)

Эмбединги и Векторное хранилище




Retrieval Augmented Generation (RAG)

Выборка по запросу и Reranking (кросс-энкодер)

Векторная БД выдаёт список документов


Реранкер дополнительно оценивает их релевантность

Улучшение результата поиска



Retrieval Augmented Generation (RAG)

обработка контекста с помощью LLM и выдача результата



Литература

Борисов Е.С. Методы машинного обучения. 2024

https://github.com/mechanoid5/ml_lectorium_2024_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2024

https://github.com/mechanoid5/ml_nlp_2024_I

Building a Complex, Production-Ready RAG System

<https://github.com/FareedKhan-dev/complex-RAG-guide>

Обзор техник RAG: Retrieval Augmented Generation

<https://habr.com/ru/articles/904032/>

Cross-Encoder для улучшения RAG на русском

<https://habr.com/ru/articles/797657/>